中心化制約付き残差成分分解を用いた小売需要の時間別予測補正

観測期間内の残差再構成と、成分ごとの働きの診断

日本経営工学会 2026年 秋季大会

東京都市大学 三川研究室

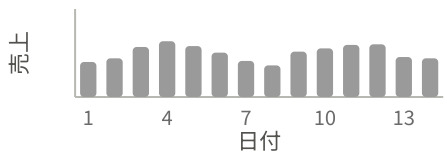
有馬 翔太

2026年10月24日

1. 背景 経営判断は予測から、予測は販売実績の「読み方」から

発注・在庫・人員の判断は需要予測に基づき、その土台は**店舗 × 商品の販売実績**である。

販売実績



店舗 × 商品ごと、ふつうは**日ごとの合計**で見る

→

需要予測

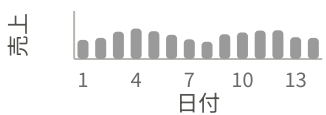
いつ・どれだけ
売れるか

→

経営判断

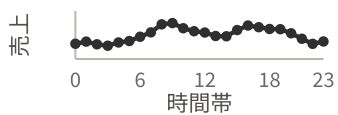
発注　在庫　人員

販売実績の変動を理解することが、需要予測と経営判断の出発点



日ごとの合計で読む
1 日 1 つの数字。
いつ売れたかは見えない

VS



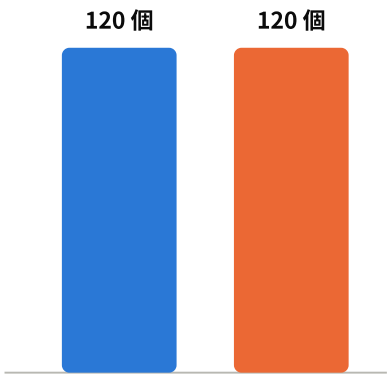
時間帯ごとまで読む
1 日 24 個の数字。
売れ方の「形」が見える

▶ 本研究では、販売実績を**日と時間帯に分けて読む方法**を検証する

1. 背景 同じ日次売上でも、時間帯の「形」が違えば打ち手が変わる

時間帯の形を**店舗を横断して**見比べれば、実績の理解が深まる —— これが本研究の仮定。

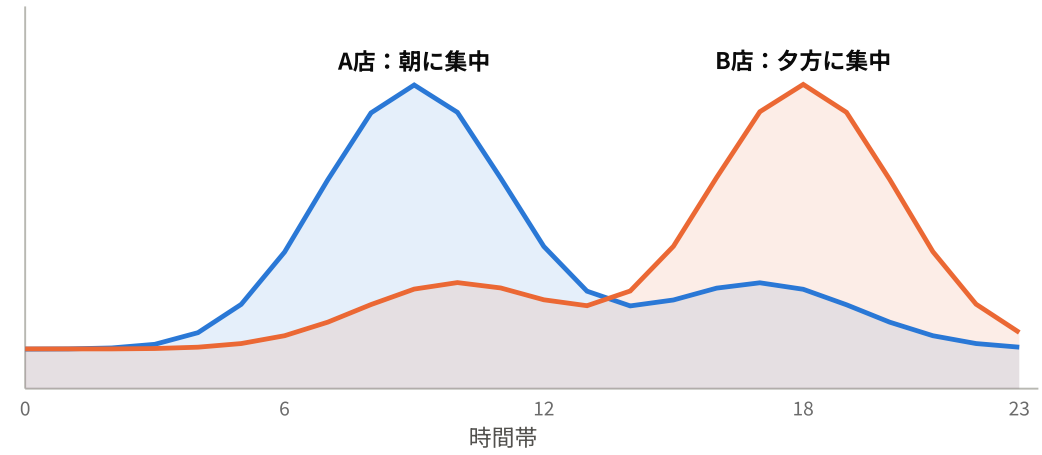
日次で見ると



同じ商品・同じ日の売上は同じ

日次だけでは区別がつかない

時間帯で見ると



A店の打ち手
開店前に補充、朝の人員を厚く

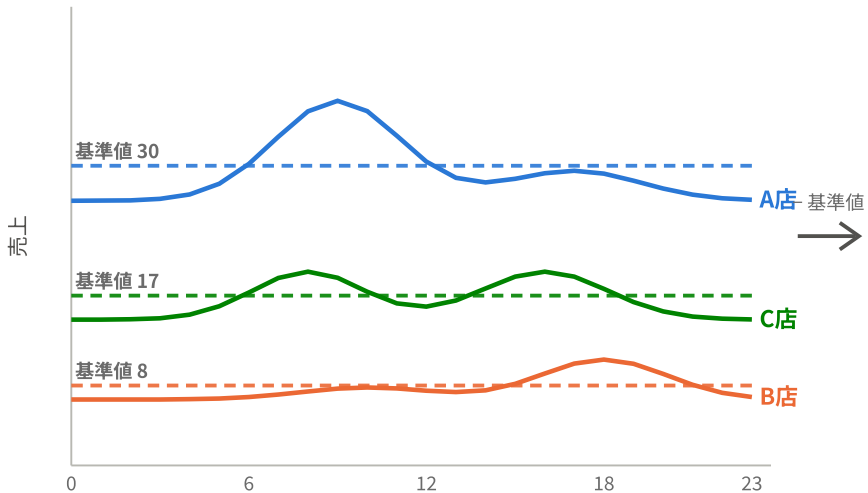
B店の打ち手
夕方前に補充、夕方の人員を厚く

▶ ただし、店舗ごとに**売上の規模**が違うと、形をそのまま重ねて比べられない

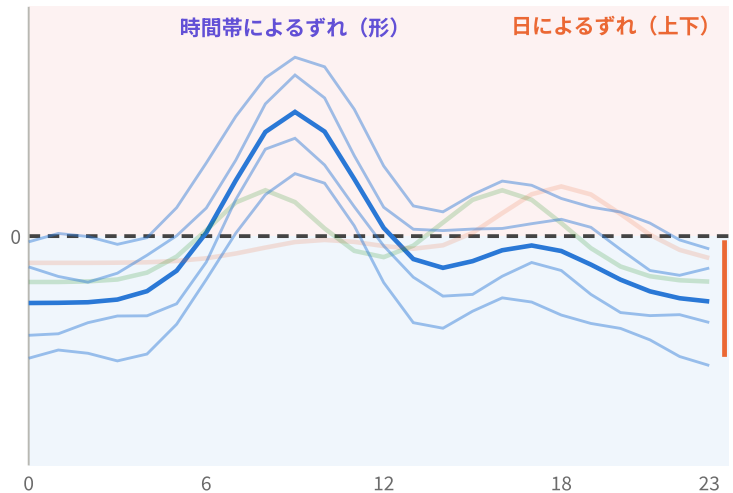
1. 背景 水準を分けた残差を、「日のずれ」と「時間帯のずれ」として読む

同じ店でも、残差は**日によって**上下にずれる。残差には「日のずれ」と「時間帯のずれ」が重なっている。

時間帯別の売上（店舗ごとに水準が違う）



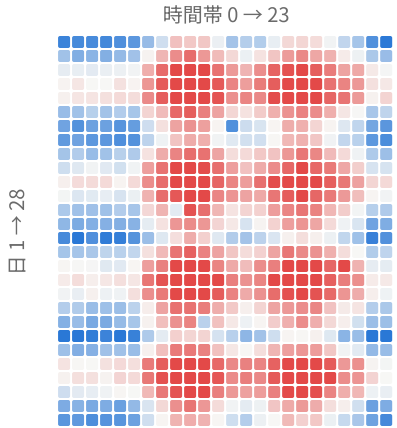
A店の残差を 4 日分重ねる（形は似て、上下にずれる）



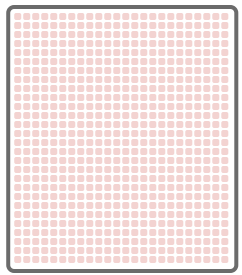
この残差を、日のずれ・時間帯のずれなど、共有される範囲ごとの表現に分けて学習し、解釈性を高めたい

2. 問題設定 残差には、共有される範囲の異なる変動が混ざっている

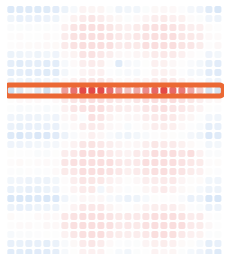
日と時間帯の 2 軸について、**全体・日・時間帯・交互作用**の 4 成分として表す。



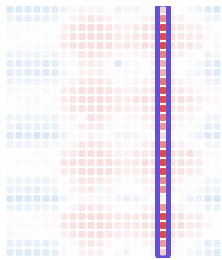
入力：1系列の観測残差（赤：正、青：負）



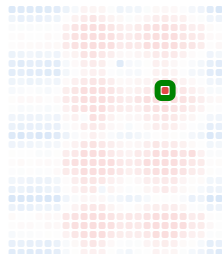
全期間に共通
全セルが
同じ向きにずれる



ある日に共通
同じ日の複数の時間帯で
同じ向きにずれる



ある時間帯に共通
複数日の同じ時間帯で
同じ向きにずれる



日 × 時間帯に固有
特定の組合せだけ
大きくずれる

推定残差 ＝ 全期間 ＋ 日 ＋ 時間帯 ＋ 交互作用

日・時間帯・交互作用は平均 0 に固定。
全格子上の推定残差の平均は**全期間成分**になる

この発表の中心

3. 研究目的 残差を 4 成分として推定する手法を提案し、精度と成分回復で有効性を示す

目的 残差を**共有範囲の異なる 4 成分の和として推定する手法**を提案し、
再構成精度と**成分の回復**で有効性を示す。成分別に読めることも確認する

なぜ合計の補正量 1 つではなく、4 成分に分けて推定するのか

① 打ち手が違う

終日の増減は**補充量**、時間帯の偏りは**配置やタイミング**に関わる。合計の補正量 1 つでは、この区別が消える。

② 共有される範囲が違う

日のずれは**同じ日の 24 時間帯**で、時間帯の形は**28 日間の同じ時間帯**で共有される。この構造を出力の形として持たせ、中心化で担当範囲を固定する。

③ 非線形に推定する

観測残差と共変量から、**成分ごとの潜在表現を経て NN で推定**する。平均の線形分解では持てない、共変量との関係を各成分に持たせる。

示すこと ① **再構成できる**：実データで誤差を比較　② **成分を回復できる**：合成データで真の成分との相関
③ **分けて読める**：量と形の区別、時間帯の形の軸、全期間成分の中身を示す

3. 研究目的 モデルの骨格：何を、どう推定するか

① 残差を定義する

$$r_{i,d,h} = y_{i,d,h} - b_i$$

$y_{i,d,h}$：店舗×商品 i の、日 d・時間帯 h の売上

b_i：系列平均（欠品セルを除く）＝ 売上の**水準**

② 残差を 4 成分の和で表す

$$\hat{r}_{i,d,h} = \hat{g}_i + \hat{a}_{i,d} + \hat{t}_{i,h} + \hat{u}_{i,d,h}$$

$\hat{g}_i$ 全期間 ／ $\hat{a}_{i,d}$ 日 ／ $\hat{t}_{i,h}$ 時間帯 ／ $\hat{u}_{i,d,h}$ 交互作用

③ 各成分は潜在表現の非線形関数

$$\hat{a}_{i,d} = f_a(z_{a,i,d}), \qquad \hat{t}_{i,h} = f_t(z_{t,i,h})$$
$$\hat{g}_i = f_g(z_{g,i}), \qquad \hat{u}_{i,d,h} = f_u(z_{u,i,d,h})$$

z：Encoder が残差と共変量から得る**成分ごとの潜在表現**

f：MLP。「和」なのは成分どうしで、**各成分の中身は非線形**

④ 学習と使い方

$$\min \sum_{d,h} m_{i,d,h} \left| r_{i,d,h} - \hat{r}_{i,d,h} \right|$$

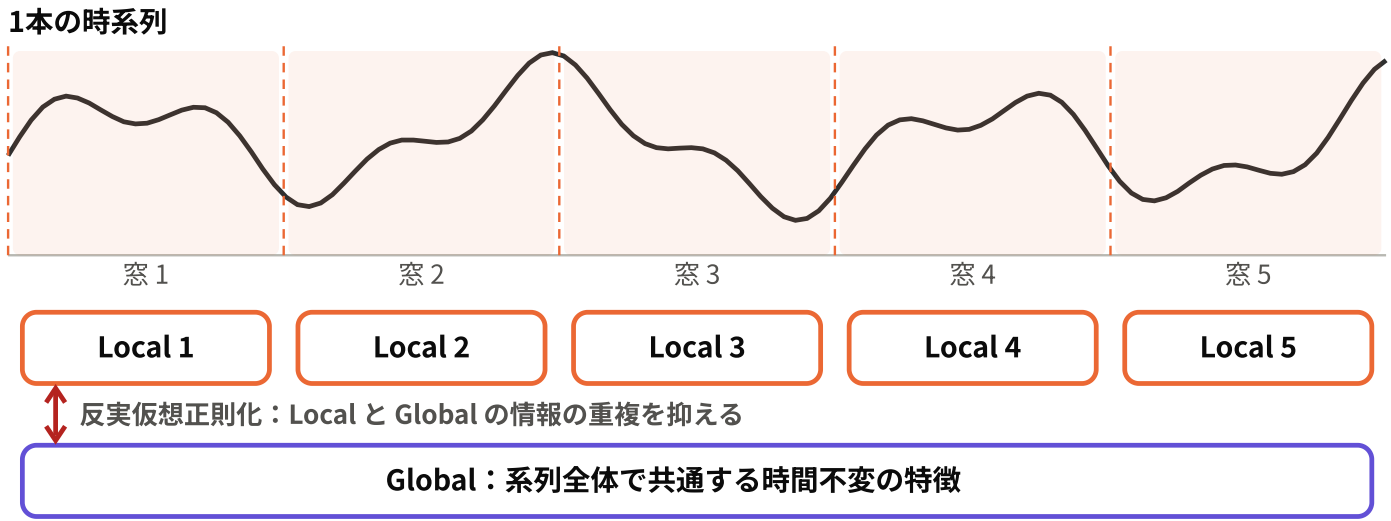
観測セル上の絶対誤差を最小化（m：観測マスク、欠品は 0）

中心化制約は $\hat{a}, \hat{t}, \hat{u}$ に適用。推定値は $\hat{y}_{i,d,h} = b_i + \hat{r}_{i,d,h}$

式 1 本の「分解」ではなく、潜在表現 → 非線形な成分 → 和 という内部構造を持つモデル

4. 従来研究 Global / Local 分離表現学習

Tonekaboni ら (2022) は、1本の時系列を窓に分け、**時間不変な Global** と**窓ごとに変化する Local** を分けて学習した。



Local：窓ごとに変化する状態（時間変動）

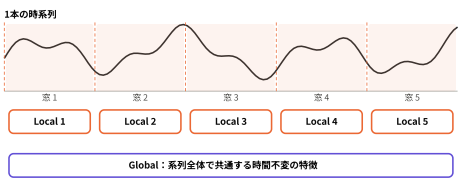
正解ラベルなしで 2 種類の潜在表現に分け、反実仮想正則化で両者の情報の重複を抑える

Tonekaboni et al., "Decoupling Local and Global Representations of Time Series," AISTATS 2022

4. 従来研究 この枠組みを日 × 時間帯の残差にそのまま使うと、何が起きるか

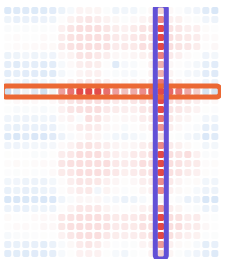
そこで本研究は、共有範囲ごとに成分を**明示的に定義**し、**中心化制約**で内訳を固定する。

① 変動が共有される範囲



比較対象：窓の並び 1 次元の Local

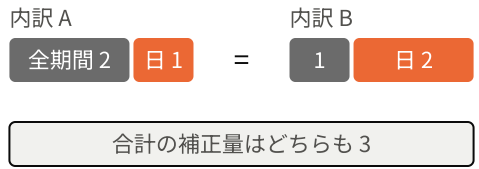
VS



本研究：日方向と時間帯方向の 2 種類の共有

Local は窓の並びに沿った 1 次元。「同じ日の複数時間帯」と「複数日の同じ時間帯」という 2 方向の共有を、別々の成分として明示的に定義していない。

② 各成分の寄与を明確にすること



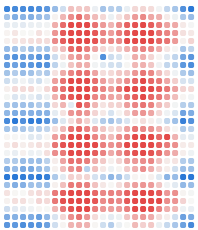
潜在表現からは各変動の寄与を直接読み取れるとは限らない。補正量を複数成分の和で表すと、内訳が一意に定まらない。

→ 本研究：残差の 4 成分分解 ＋ 中心化制約

全体像

5. 提案手法 青写真：分解する → 非線形に表現する → 足し合わせる

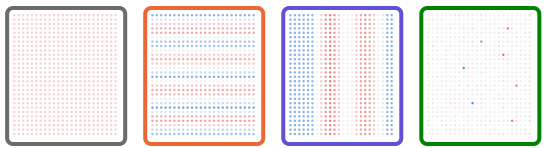
観測残差



店舗×商品ごと
28日×24時間帯

① 分解 →

共有範囲の異なる 4 成分



全期間　日　時間帯　交互作用

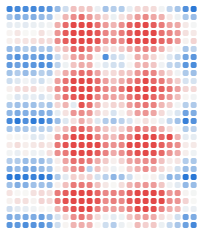
② 表現 →

成分ごとの潜在表現 → 非線形

z_g → MLP → $\hat{g}$
$z_{a,d}$ → MLP → $\hat{a}_d$
$z_{t,h}$ → MLP → $\hat{t_h}$
$z_{u,d,h}$ → MLP → $\hat{u}_{d,h}$

③ 加算 →

推定残差



＋ 基準値
→ 売上の推定値

残差を扱う役割：平均水準を分ける

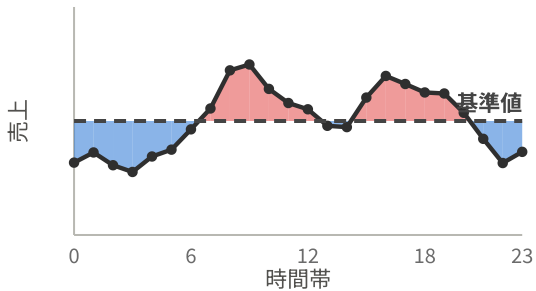
系列平均を基準値として分け、その上下の変動を学習する。振幅の規模差は残るため、形の比較では別に扱う。

中心化制約の役割：日・時間帯・交互作用を分離する

和で表すだけでは内訳が決まらない。各成分の平均を対応する方向で 0 に固定し、担当範囲を一意にする。

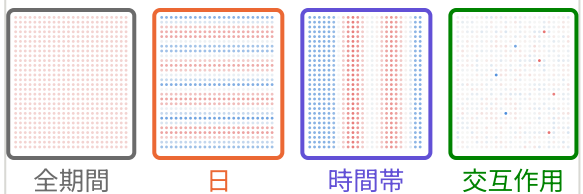
5. 提案手法 概要：3 つの特徴

① 残差に着目



観測売上を直接ではなく、
基準値を差し引いた残差をモデル化

② 4 成分を非線形に推定し、足す



成分ごとの潜在表現から MLP で推定。
和は成分どうし、**各成分の中身は非線形**

③ 中心化制約

日方向の平均 = 0

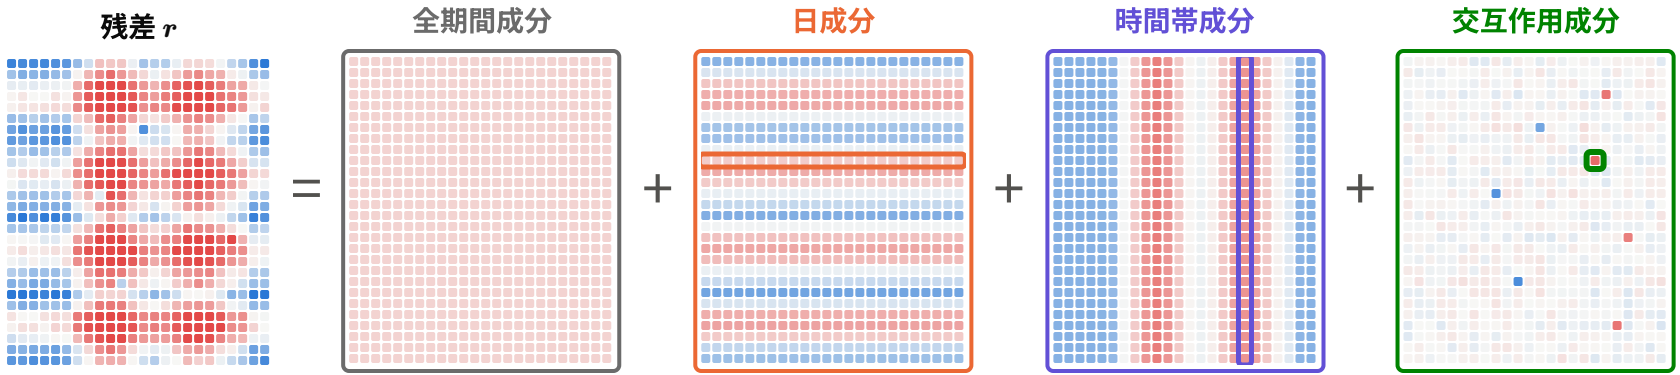
時間帯方向の平均 = 0

交互作用は両方向で 0

出力するだけでは定まらない
成分の役割を共有構造に対応させる

5. 提案手法 各成分の意味

各成分は、残差が**どの範囲で共有されるか**に対応する。



全期間成分
全セルへ同じ値を加える項。基準値の水準ずれを吸収する

日成分
ある日の複数の時間帯に共通する変動

時間帯成分
複数日の同じ時間帯に共通して現れる変動

交互作用成分
日・時間帯では説明できない、特定の組合せに固有の変動

5. 提案手法

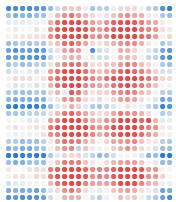
モデルの全体像：Encoder → 潜在表現 → Decoder → 中心化 → 加算

中心化された 4 成分を加算して**推定残差**とし、基準値に加えて売上の推定値を得る。

提案の核心

5. 提案手法 肝：オートエンコーダ構造で、成分ごとの潜在表現を獲得する

入力



観測残差 ＋ 共変量

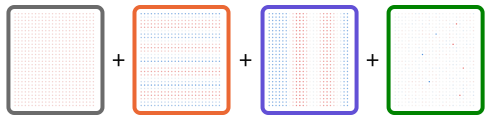
Encoder →

潜在表現（成分ごと・低次元）

- z_g 系列に 1 本（10 次元）
- $z_{a,d}$ 日ごとに 1 本（28 本 × 10 次元）
- $z_{t,h}$ 時間帯ごとに 1 本（24 本 × 10 次元）
- $z_{u,d,h}$ $z_a \oplus z_t$ から（28 × 24 本 × 8 次元）

Decoder →

4 成分 → 中心化 → Σ



→ 推定残差（入力を再構成）

① 「どこが効いたか」が成分ごとに残る
出力を成分別に持つため、推定した補正量と誤差への影響を、共有範囲ごとに調べられる。

② 中心化で出力の担当範囲を固定
各成分の平均を対応する方向で 0 にし、全格子上で出力の内訳を一意にする。潜在 z の次元の意味までは定めない。

③ 成分の回復を直接検証できる
出力が成分別なので、真の成分を埋め込んだ合成データで、意図した成分を回復したかを相関で測れる。

5. 提案手法

中心化制約 (1/2)：和で表すだけでは、内訳が一意に決まらない

移せる量 ＝ **日成分の平均**。これを **0 に固定**すれば移せなくなり、内訳は A に定まる。

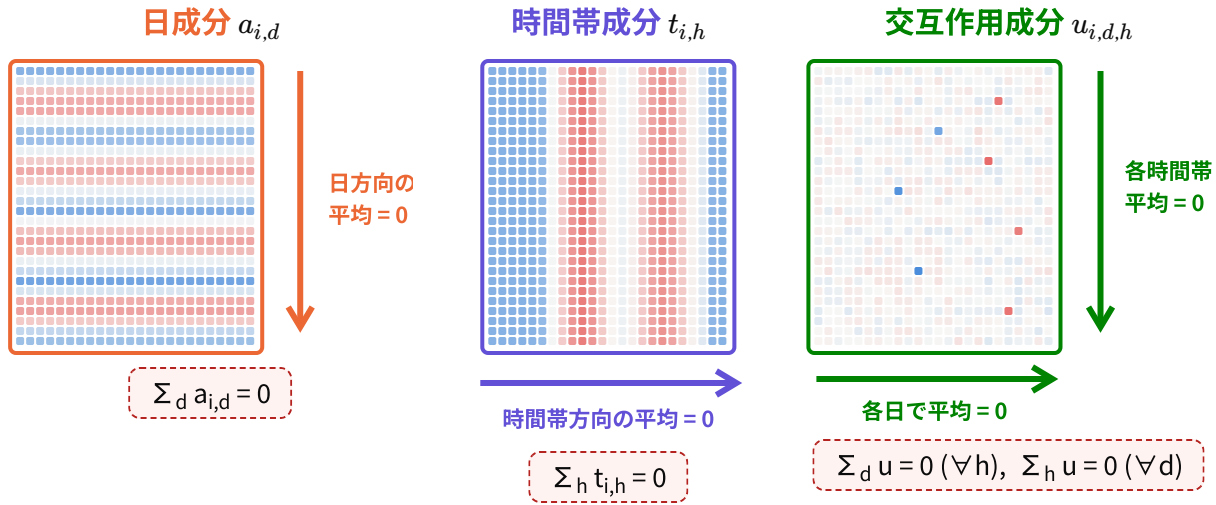


読み方：日成分に全日共通の定数を足すと、全期間成分と区別がつかない。
その定数が「日成分の平均」として現れる。

時間帯成分・交互作用成分でも同じことが起きる。
→ 次ページ：成分ごとに、どの方向の平均を 0 にするかを決める

中心化制約 (2/2)：各成分の担当範囲を固定する

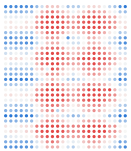
日成分は**日方向**、時間帯成分は**時間帯方向**、交互作用成分は**両方向**で平均を 0 にする。



中心化制約は、残差の合計を求めるためではなく、内訳を明確にするための仕組み

6. 実験 実験設定

実データ：FreshRetailNet-50K（生鮮小売の公開データ）



店舗 × 商品 ＝ 1 系列、28日 × 24時間帯
観測残差を入力し、**同じ期間の残差を再構成**

データ分割（系列数）

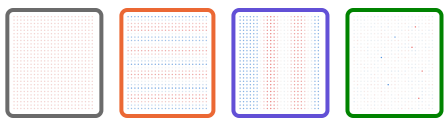
学習 6,000	検証 1,500	評価 1,500

評価指標　MAE ／ 残差 Top10 MAE（残差が大きい上位 10% セルの誤差）

比較手法

- **基準値のみ**　：残差補正なし
- **中心化なし**　：4 成分モデル（制約を外す）
- **提案**　：4 成分モデル ＋ 中心化制約

合成データ：成分が正しく取り出せるか



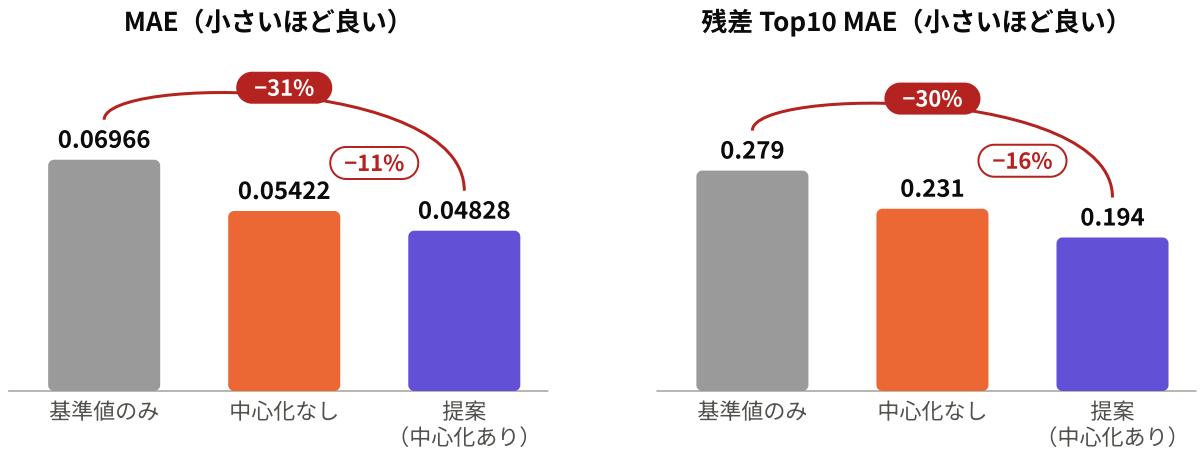
真の 4 成分から生成し、
中心化の有無で再構成誤差と
成分回復（相関）を比較

学習条件　**Encoder**　集約特徴（平均・標準偏差）→ 成分ごとの NN、隠れ 160　**潜在次元**　全期間 10・日 10・時間帯 10・交互作用 8
Decoder　成分ごとに 2 層 MLP（ReLU, Dropout 0.1）　**損失**　観測セル上の絶対誤差（欠品除外）　**最適化**　AdamW, lr 1e-3, weight decay 1e-4, batch 128
epoch　最大 60、検証損失で早期終了（patience 8）　**試行**　5 seed の平均　詳細は Appendix

6. 実験

実データ：残差再構成誤差

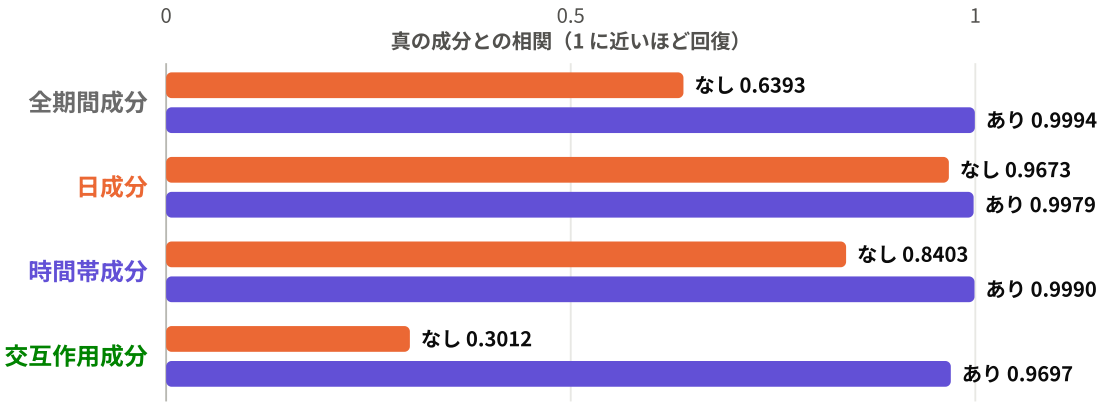
対象条件で**残差再構成誤差が改善**。中心化の改善幅は学習予算にも依存する。



2-Exp-40：最大 60 epoch／patience 8、5 seed 平均。同じ観測期間の再構成を評価

6. 実験 合成データ：意図した成分を回復できているか

中心化ありは 4 成分すべて **0.97 以上**。**再構成誤差が小さい ≠ 成分が正しい**。



残差 MAE

- 中心化あり（提案） **0.0963**
- 中心化なし **0.1068**
- 潜在空間で分解 **0.1680**

潜在空間で分解：4 つの潜在表現を連結して 1 つの Decoder で残差を出力（成分別の出力を持たない）

相関の求め方

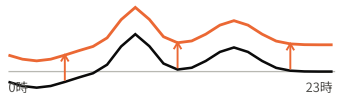
観測セル上で、真の成分と推定成分の Pearson 相関（全系列をまとめて計算）。**中心化なしは、推定 4 成分に直交 Procrustes 回転をかけて真の成分に最も近づけてから計算**（全体の二乗誤差が最小となる回転。相関の上限ではない）。式は付録

7. 考察 (1/3)

「量」と「形」は比喩ではなく、中心化の制約の言い換え

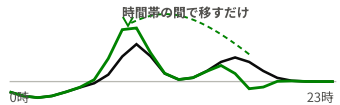
日成分は**形を変えられず**、交互作用は**総量を変えられない**。2 つは構造上、排他的な役割を持つ。

日成分：24 時間帯で同じ値



平行移動しかできない → **形は変えられない＝量**

交互作用：その日の 24 時間帯の合計 = 0



合計を増やせない → **総量は変えられない＝形**

量 ＝ その日の日成分（24 時間帯で同じ値）　形 ＝ その日の交互作用の RMS。
中心化がなければ交互作用が総量も動かせるので、この区別自体が成立しない。

割引は形を、休日は量を動かす。モデルなしの実測でも同じ向き

共変量との相関	提案モデル		実測のみ	
	量	形	量	形
割引の深さ	+0.10	**+0.21**	+0.12	**+0.38**
休日	**+0.25**	+0.10	**+0.16**	+0.10
販促フラグ	+0.10	+0.01	+0.09	+0.01
降水量	+0.14	+0.05	+0.13	+0.06

4 つとも向きが一致。対比は**データにもともとある構造**で、モデルは雑音を落として 2 つの成分に振り分けている（休日×量 0.16 → 0.25）。

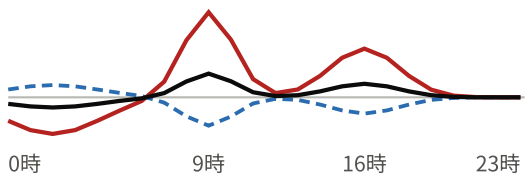
評価 1,500 系列 × 28 日。240 epoch・5 seed 平均、5 seed すべて同じ向き。60 epoch でも同順。実測＝生の残差の日平均と、日平均を引いた RMS。割引の深さ＝1−価格比

2 つの軸で効く要因が違う。量なら総量、形なら時間帯配分に関わる打ち手を分けて検証できる

7. 考察 (2/3) 時間帯の形は、実質 3 つのつまみで表せる

Decoder が出した時間帯カーブ（1,479 系列 × 24 時間帯）を主成分分析。**5 seed すべてで同じ 3 軸**が出る。

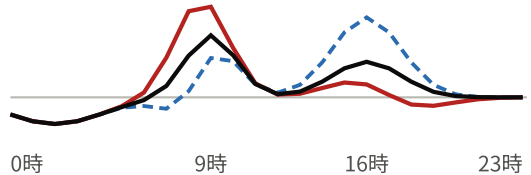
PC1 82% リズムの強さ（振幅）



山谷の位置は動かず、カーブ全体が引き伸ばされる

帰属（out-of-fold R^2）：商品 0.86 ／ 店舗 −0.03

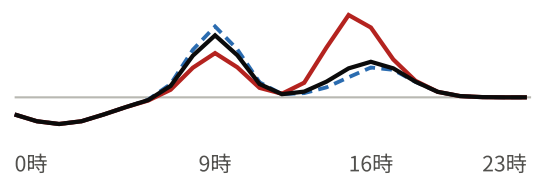
PC2 6% 朝型 ⇔ 夕方型



朝の山が伸びると夕方の肩が削れるシーソー

帰属（out-of-fold R^2）：商品 0.32 ／ 店舗 0.11

PC3 3% 午後の山があるか



14〜16 時に山が立つ。ここだけ店舗側の軸

帰属（out-of-fold R^2）：商品 −0.11 ／ 店舗 +0.16

模式図。黒：平均カーブ　赤：+2SD　青破線：−2SD。帰属は店舗 ID・商品 ID で座標を説明した out-of-fold R^2

売れ方の違いは、いつ売れるかより「メリハリ」
振幅の軸だけで 82%。朝型か夕方型かは 6%、午後の山は 3%。残り 9% はどの軸にも乗らない日々の揺れ。

メリハリは商品、午後の山は店舗の性質
軸が小さいほど所有者が商品から店舗へ移る階層。ただし振幅は売上水準とほぼ比例し、「商品」には水準の効果が含まれる（相対振幅では R^2 0.21）。PC3 の店舗差は平均のずれで、分離はしない。

型ではなく、連続な軸
同じデータの K-means はシルエット 0.08、seed 間 ARI 0.37〜0.89 で不安定。PCA の軸は 6° 以内、座標の相関 0.95〜0.999 で再現。

7. 考察 (3/3) 成分ごとに精査すると、次に直す場所が決まる

各成分は意図した担当範囲を保っている。**その中身を見ると、設計の次の一手が見える。**

残る過小推定は、全期間成分 1 つに集まった

観測セル上の相対 bias	5 seed
予測全体	**−0.262**
うち全期間成分 g	**−0.305**
残り 3 成分	+0.043

「全セル共通のずれの受け皿」という役割どおり。集まった中身は需要の水準ではなく、**平均基準と L1 損失の組合せが生む系統誤差**（最適値は残りの中央値）。中心化なしでは試行ごとに担当が入れ替わり、特定できない。

→ 直す場所は基準値。中央値にすればこの成分は空になる見込み

日成分は、理由のつく動きだけを残していた

実測の日ごとのずれと比べて	
相関	**0.91〜0.95**
振幅	約 1/2
共変量で説明できる割合	7% → **11%**

雑音を落とし、割引・休日・天候で説明のつく部分を保持している。**観測のない日にも共変量から日成分を出す足場**になる。

未知日での精度は未検証。2-Exp-47

今回の結果から言える範囲

言える

全格子上で出力の担当範囲が定まる。同期間の残差を再構成し、成分別に読める。

言えない

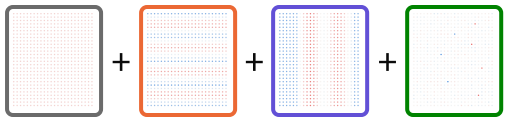
未知日の予測精度、販促などの因果効果、発注・配置への効果。成分別の読みも同じ 28 日の中の話（過去窓 → 将来窓は検証中）。

条件つき

中心化の精度差 11% は学習予算で縮む（240 epoch で −0.0015、Appendix）。観測セル上では成分間の漏れが残る。

8. まとめ 担当範囲の定まる 4 成分で残差を推定し、精度と成分回復を示した

提案したこと



残差を共有範囲の異なる 4 成分の和として非線形に推定。

中心化制約で、成分の担当範囲を一意に固定した。

実験で示したこと

実データの再構成

MAE は基準値比 約31%、中心化なし比 約11% 低減。

最大 60 epoch の条件。長時間学習では差は縮小。

合成データの成分回復

4 成分すべて相関 0.97 以上（中心化なしは 0.30〜0.97）。

12 epoch・1 seed。中心化なしは回転後の値。

分けたことで読めたこと

量と形は中心化の制約が決める排他的な役割。割引は形を、休日は量を動かす。

時間帯の形は**3 つのつまみ**。メリハリ（82%）は商品、午後の山は店舗の性質。

残る過小推定は全期間成分 1 つに集まり、**直す場所（基準値）が定まった。**

今後：基準値の中央値化、未知日への一般化、発注・配置への有効性の検証

本発表の主評価は、観測残差を入力した同期間の再構成と成分回復。

Appendix 実験条件の詳細

項目	実データ（FreshRetailNet-50K）	合成データ
データ	店舗×商品 = 1 系列、28日 × 24時間帯。学習 6,000 ／ 検証 1,500 ／ 評価 1,500 系列	1,500 系列、35日 × 24時間帯。真の 4 成分 + ノイズ（σ = 0.12）、欠品率 3%
基準値	系列平均（欠品セルを除く）	直近 7 日の同時間帯平均
入力	28日 × 24時間帯 × 13チャネル：残差・欠品フラグ・日次共変量7本・周期特徴4本（次頁）	同構成
Encoder	チャネル別マスクで平均・SDを集約。全期間・時間帯：MLP、日：GRU、交互作用：日・時間帯潜在を連結したMLP（詳細は付録）	同構成
Decoder	成分ごとに Linear(→160)–ReLU–Dropout(0.1)–Linear(→1)	同構成
中心化	日成分：日方向平均 0、時間帯成分：時間帯方向平均 0、交互作用成分：両方向平均 0	同構成
損失	観測セル上の絶対誤差（欠品除外）＋ 潜在表現間の共分散ペナルティ（重み 0.01）	同構成
最適化	AdamW（lr 1e-3、weight decay 1e-4）、batch 128、勾配クリップ 1.0、混合精度	同構成
epoch	最大 60、検証再構成損失で早期終了（patience 8）、最良検証エポックを採用	12
試行	5 seed（17, 23, 31, 47, 59）の平均	1 seed
比較手法	基準値のみ／中心化なし／提案	中心化なし／提案／潜在空間で分解（4 潜在表現を連結し 1 つの Decoder で残差を出力、成分別出力なし）
評価	MAE・残差Top10 MAE（定義は付録「評価指標」）	残差MAE・真の成分との相関。中心化なしは事後の直交整合後（定義と前処理の注意は付録「成分回復」）

Appendix 記号と入力：観測値・マスク・潜在表現を区別する

対象：実データ主実験（系列平均基準）

記号	定義・形
$i = 1, \dots, N$	店舗 × 商品の系列。N は対象集合の系列数
$d = 0, \dots, D-1$	入力期間の相対日番号、$D = 28$
$h = 0, \dots, H-1$	時間帯、$H = 24$
$j = 0, \dots, F-1$	入力チャネル、$F = 13$
$y_{i,d,h},\ b_i,\ r_{i,d,h}$	売上、固定した基準値、残差（スカラー）
$s_{i,d,h},\ m_{i,d,h}$	欠品フラグ（1：欠品）、観測マスク（1：観測）
$\mathbf{x}_{i,d,h} \in \mathbb{R}^{13}$	セルの入力ベクトル。$x_{i,d,h,j}$ は第 j チャネル
$\mathbf{X}_i, \mathbf{M}_i$	入力とチャネル別マスク。形は $D \times H \times F$

太字はベクトル・行列・テンソル、$[\cdot;\cdot]$ は連結。
$\mathbf{z}$：潜在ベクトル、$\tilde{a}, \tilde{t}, \tilde{u}$：中心化前、$\hat{g}, \hat{a}, \hat{t}, \hat{u}$：最終出力。

基準値と残差（観測セルの平均）

$$m_{i,d,h} = 1\{s_{i,d,h} \neq 1\}$$

$$b_i = \frac{\sum_{d,h} m_{i,d,h} y_{i,d,h}}{\max(\sum_{d,h} m_{i,d,h}, 1)}, \qquad r_{i,d,h} = y_{i,d,h} - b_i$$

13 チャネルの内訳

$$\mathbf{x}_{i,d,h} = [\, r_{i,d,h};\ s_{i,d,h};\ \mathbf{v}_{i,d};\ \boldsymbol{\phi}_h;\ \boldsymbol{\psi}_d \,]$$

$\mathbf{v}_{i,d} \in \mathbb{R}^7$：割引・休日・販促・降水・気温・湿度・風（日内で一定）。

$$\boldsymbol{\phi}_h = [\sin(2\pi h/H); \cos(2\pi h/H)]$$

$$\boldsymbol{\psi}_d = [\sin(2\pi q_d/7); \cos(2\pi q_d/7)], \quad q_d = d \bmod 7$$

q_d は実装上の相対的な 7 日周期位置。暦上の曜日そのものとは限らない。

$$M_{i,d,h,j} = \begin{cases} m_{i,d,h} & j = 0 \\ 1 & j = 1, \dots, 12 \end{cases}$$

損失は m、Encoder の集約はチャネル別の M を使う。

Appendix Encoder の前処理：何を、どの方向で集約するか

集約するセル集合 S（1 系列内）

$$S_g = \{0,\dots,D-1\} \times \{0,\dots,H-1\}$$
$$S_{a,d} = \{(d,h') : h' = 0,\dots,H-1\}$$
$$S_{t,h} = \{(d',h) : d' = 0,\dots,D-1\}$$

集合	集約する範囲	残る単位
S_g	28 日 × 24 時間帯	系列ごとに 1 本
$S_{a,d}$	日 d の 24 時間帯	日ごとに 1 本
$S_{t,h}$	時間帯 h の 28 日	時間帯ごとに 1 本

集約特徴（$\boldsymbol{\mu}_i(S), \boldsymbol{\sigma}_i(S) \in \mathbb{R}^F$）

$$\boldsymbol{\eta}_i(S) = [\boldsymbol{\mu}_i(S); \boldsymbol{\sigma}_i(S)] \in \mathbb{R}^{2F}$$

ここで $F = 13$ なので、NN に入る要約は **26 次元**。
平均・標準偏差への集約は固定処理で、学習パラメータを持たない。

チャネル j ごとの平均・標準偏差

$$n_{i,j}(S) = \max\left(\sum_{(d,h)\in S} M_{i,d,h,j},\ 1\right)$$
$$\mu_{i,j}(S) = \frac{\sum_{(d,h)\in S} M_{i,d,h,j}\, x_{i,d,h,j}}{n_{i,j}(S)}$$
$$\tau_{i,j}(S) = \frac{\sum_{(d,h)\in S} M_{i,d,h,j}\big(x_{i,d,h,j} - \mu_{i,j}(S)\big)^2}{n_{i,j}(S)}$$
$$\sigma_{i,j}(S) = \sqrt{\tau_{i,j}(S) + \varepsilon}, \qquad \varepsilon = 10^{-6}$$

τ：分散、ε：平方根の安定化定数。分散の分母は観測数（不偏分散ではない）。

各 Encoder に見える共変量

- 日：その日の $\mathbf{v}_{i,d}$ と、ほぼ 0 の日内 SD。
- 時間帯：日次共変量の期間平均・SD は全時間帯で共通。残差・欠品フラグの統計と時間帯の周期特徴は時間帯ごとに異なる。
- 全期間：共変量の期間平均・SD を受け取る。

共変量は日 Encoder だけに入るわけではない。
日ごとの情報と、期間全体に要約された情報を区別する。

Appendix Encoder の構造と潜在表現の形

以下は全 MLP 版（2-Exp-45）の構造。主結果（2-Exp-40）は日 Encoder に GRU を含む。

E_g, E_a, E_t, E_u は別の MLP。潜在次元は $L_g = L_a = L_t = 10,\ L_u = 8$。各 Encoder 内で重みを共有する。

成分	Encoder が受け取るもの	ネットワーク	系列 i の潜在表現
全期間	$\boldsymbol{\eta}_i(S_g) \in \mathbb{R}^{26}$	Linear(26→160) → ReLU → Linear(160→10)	$\mathbf{z}_{g,i} \in \mathbb{R}^{10}$
日	$\boldsymbol{\eta}_i(S_{a,d}) \in \mathbb{R}^{26}$（日ごと）	Linear(26→160) → ReLU → Linear(160→10)	$\mathbf{Z}_{a,i} \in \mathbb{R}^{28\times 10}$
時間帯	$\boldsymbol{\eta}_i(S_{t,h}) \in \mathbb{R}^{26}$	Linear(26→160) → ReLU → Linear(160→10)	$\mathbf{Z}_{t,i} \in \mathbb{R}^{24\times 10}$
交互作用	$[\mathbf{z}_{a,i,d}; \mathbf{z}_{t,i,h}] \in \mathbb{R}^{20}$	Linear(20→160) → ReLU → Linear(160→8)	$\mathbf{Z}_{u,i} \in \mathbb{R}^{28\times 24\times 8}$

Encoder の中身（$k \in \{g, a, t\}$ で共通の形）

$$\mathbf{p} = \mathrm{ReLU}\big(W_k^{\mathrm{in}} \boldsymbol{\eta}_i(S) + \mathbf{b}_k^{\mathrm{in}}\big)$$

$$E_k(\boldsymbol{\eta}_i(S)) = W_k^{\mathrm{out}} \mathbf{p} + \mathbf{b}_k^{\mathrm{out}}$$

$\mathbf{p} \in \mathbb{R}^{160}$。$W^{\mathrm{in}} \in \mathbb{R}^{160\times 26}$、$W^{\mathrm{out}} \in \mathbb{R}^{L_k\times 160}$。$\mathbf{b}^{\mathrm{in}} \in \mathbb{R}^{160}, \mathbf{b}^{\mathrm{out}} \in \mathbb{R}^{L_k}$ は学習するバイアス（基準値 b_i とは別）。日 Encoder は $S_{a,d}$ を日ごとに、時間帯 Encoder は $S_{t,h}$ を時間帯ごとに、同じ重みで処理する。

各範囲の特徴から潜在表現へ

$$\mathbf{z}_{g,i} = E_g(\boldsymbol{\eta}_i(S_g))$$

$$\mathbf{z}_{a,i,d} = E_a(\boldsymbol{\eta}_i(S_{a,d})), \quad \mathbf{z}_{t,i,h} = E_t(\boldsymbol{\eta}_i(S_{t,h}))$$

$$\mathbf{z}_{u,i,d,h} = E_u([\mathbf{z}_{a,i,d}; \mathbf{z}_{t,i,h}])$$

$\mathbf{Z}_a$ の第 d 行が $\mathbf{z}_{a,i,d}^\top$、$\mathbf{Z}_t$ の第 h 行が $\mathbf{z}_{t,i,h}^\top$。$\mathbf{Z}_u$ はセルごとの潜在ベクトルを並べたもの。

日単位の出力でも、潜在の各次元の意味は固定されない。

Appendix Decoder と中心化：生出力と最終成分を区別する

成分別 Decoder $f_k : \mathbb{R}^{L_k} \to \mathbb{R}$

$k \in \{g, a, t, u\}$。各 f_k は別の重みを持つ。

Linear(L_k→160) → ReLU → Dropout(0.1) → Linear(160→1)

$$\hat{g}_i = f_g(\mathbf{z}_{g,i}), \qquad \tilde{a}_{i,d} = f_a(\mathbf{z}_{a,i,d})$$
$$\tilde{t}_{i,h} = f_t(\mathbf{z}_{t,i,h}), \qquad \tilde{u}_{i,d,h} = f_u(\mathbf{z}_{u,i,d,h})$$

中心化後の成分を加算

$$\hat{r}_{i,d,h} = \hat{g}_i + \hat{a}_{i,d} + \hat{t}_{i,h} + \hat{u}_{i,d,h}$$
$$\hat{y}_{i,d,h} = b_i + \hat{r}_{i,d,h}$$

成分	スカラー出力の共有範囲
$\hat{g}_i$	全 $D \times H$ セル
$\hat{a}_{i,d}$	同じ日 d の全時間帯
$\hat{t}_{i,h}$	同じ時間帯 h の全日
$\hat{u}_{i,d,h}$	そのセル

全格子上で平均 0 にする（マスクを使わない）

$$\hat{a}_{i,d} = \tilde{a}_{i,d} - \frac{1}{D}\sum_{d'} \tilde{a}_{i,d'}$$
$$\hat{t}_{i,h} = \tilde{t}_{i,h} - \frac{1}{H}\sum_{h'} \tilde{t}_{i,h'}$$
$$\hat{u}_{i,d,h} = \tilde{u}_{i,d,h} - \frac{1}{D}\sum_{d'} \tilde{u}_{i,d',h} - \frac{1}{H}\sum_{h'} \tilde{u}_{i,d,h'} + \frac{1}{DH}\sum_{d',h'} \tilde{u}_{i,d',h'}$$

d', h' は総和用の添字。$\hat{g}_i$ は中心化しない。

$$\sum_d \hat{a}_{i,d} = 0, \qquad \sum_h \hat{t}_{i,h} = 0$$
$$\sum_d \hat{u}_{i,d,h} = 0 \ (\forall h), \quad \sum_h \hat{u}_{i,d,h} = 0 \ (\forall d)$$

したがって $\frac{1}{DH}\sum_{d,h} \hat{r}_{i,d,h} = \hat{g}_i$。

固定した推定面の内訳を定める制約であり、潜在次元の意味や観測セル上の直交性を保証しない。

Appendix 学習損失：再構成誤差と潜在表現の共分散

ミニバッチ $\mathcal{B}$（系列集合、$B = |\mathcal{B}|$）

$$\mathcal{L}_{\mathcal{B}} = \mathcal{L}_{\text{rec}} + \lambda \mathcal{L}_{\text{cov}}, \qquad \lambda = 0.01$$

$$\mathcal{L}_{\text{rec}} = \frac{\sum_{i \in \mathcal{B}} \sum_{d,h} m_{i,d,h} |r_{i,d,h} - \hat{r}_{i,d,h}|}{\max(\sum_{i \in \mathcal{B}} \sum_{d,h} m_{i,d,h}, 1)}$$

欠品セルを除いたセル単位の平均。系列ごとに MAE を平均する式とは異なる。

系列ごとに要約する潜在ベクトル

$$\bar{\mathbf{z}}_{g,i} = \mathbf{z}_{g,i}$$

$$\bar{\mathbf{z}}_{a,i} = \frac{1}{D} \sum_{d} \mathbf{z}_{a,i,d}, \qquad \bar{\mathbf{z}}_{t,i} = \frac{1}{H} \sum_{h} \mathbf{z}_{t,i,h}$$

この平均は全日・全時間帯で取り、観測マスクを使わない。対象は g, a, t **の 3 ブロック**。交互作用 u はこのペナルティに含めない。

バッチ内で系列間の共分散を計算

$$\boldsymbol{\nu}_k = \frac{1}{B} \sum_{i \in \mathcal{B}} \bar{\mathbf{z}}_{k,i}, \qquad k \in \{g, a, t\}$$

$$\mathbf{V}_{kl} = \frac{\sum_{i \in \mathcal{B}} (\bar{\mathbf{z}}_{k,i} - \boldsymbol{\nu}_k)(\bar{\mathbf{z}}_{l,i} - \boldsymbol{\nu}_l)^{\top}}{\max(B - 1, 1)}$$

$\mathbf{V}_{kl} \in \mathbb{R}^{L_k \times L_l}$ は交差共分散行列。

$$\mathcal{P} = \{(g,a), (g,t), (a,t)\}$$

$$\mathcal{L}_{\text{cov}} = \sum_{(k,l) \in \mathcal{P}} \frac{\|\mathbf{V}_{kl}\|_F^2}{L_k L_l}$$

$\|A\|_F^2 = \sum_{p,q} A_{p,q}^2$：全要素の二乗和。
$L_k L_l$ で割るため、各共分散行列の二乗要素平均を足す。

出力中心化と、潜在の共分散ペナルティは別。
前者は恒等的な制約、後者は学習時の罰則。無相関や統計的独立を厳密に保証するものではない。

Appendix 評価指標：誤差・分散比・成分除去

評価するセル集合を固定

$$\Omega = \{(i,d,h) : i \in \mathcal{I}_{\text{eval}},\ m_{i,d,h} = 1\}$$

$\mathcal{I}_{\text{eval}}$：評価系列の集合。$\boldsymbol{r}, \hat{\boldsymbol{r}} \in \mathbb{R}^{|\Omega|}$ は同じ順序で残差を並べたベクトル。

残差予測ベクトル $\boldsymbol{p}$ に対する MAE

$$\ell_\Omega(\boldsymbol{p}) = \frac{1}{|\Omega|} \sum_{n=1}^{|\Omega|} |r_n - p_n|$$

主実験では $\hat{y} = b + \hat{r}$ なので、$\ell_\Omega(\hat{\boldsymbol{r}})$ は売上の MAE と一致する。

残差 Top10 MAE

$|r|$ の観測セル上の 90% 分位点以上を選び、その集合で同じ MAE を計算。同値を含むため、セル数が厳密に 10% とは限らない。

成分を抜いたときの変化（再学習なし）

$$\Delta_k = \ell_\Omega(\hat{\boldsymbol{r}} - \hat{\boldsymbol{c}}_k) - \ell_\Omega(\hat{\boldsymbol{r}})$$

$\Delta_k > 0$：除去すると悪化。$\hat{\boldsymbol{c}}_k$ は右欄で定義。

成分を全セルへ展開し、Ω 上に並べる

$$\hat{c}_{g,i,d,h} = \hat{g}_i, \quad \hat{c}_{a,i,d,h} = \hat{a}_{i,d},$$
$$\hat{c}_{t,i,d,h} = \hat{t}_{i,h}, \quad \hat{c}_{u,i,d,h} = \hat{u}_{i,d,h}$$

$\hat{\boldsymbol{c}}_k \in \mathbb{R}^{|\Omega|}$、$k \in \{g,a,t,u\}$。以下の分散・共分散はすべて Ω 上、同じ正規化で計算。

$$s_k = \frac{\mathrm{Var}_\Omega(\hat{\boldsymbol{c}}_k)}{\mathrm{Var}_\Omega(\boldsymbol{r})}, \quad q_{kl} = \frac{2\,\mathrm{Cov}_\Omega(\hat{\boldsymbol{c}}_k, \hat{\boldsymbol{c}}_l)}{\mathrm{Var}_\Omega(\boldsymbol{r})}$$
$$\sum_k s_k + \sum_{k<l} q_{kl} = \frac{\mathrm{Var}_\Omega(\hat{\boldsymbol{r}})}{\mathrm{Var}_\Omega(\boldsymbol{r})}$$

$k < l$ は (g,a,t,u) の順で重複しない全 6 対。

$$R^2 = 1 - \frac{\sum_n (r_n - \hat{r}_n)^2}{\sum_n (r_n - \bar{r}_\Omega)^2}, \quad \bar{r}_\Omega = \frac{1}{|\Omega|} \sum_n r_n$$

分散比の合計は R^2 ではない。 全格子上の中心化も、Ω 上の交差項ゼロを保証しない。分母の分散が正の場合の定義。

Appendix 成分回復：相関と直交整合の記号

合成データの真の成分との比較

前ページと同じ方法で、真の成分 $\boldsymbol{c}_k$ と推定成分 $\hat{\boldsymbol{c}}_k$ を観測セル集合 Ω 上に並べる。

$$\rho_k = \mathrm{corr}(\boldsymbol{c}_k, \hat{\boldsymbol{c}}_k), \qquad k \in \{g, a, t, u\}$$

corr：Pearson 相関。成分ベクトルの分散が正の場合に定義。中心化ありの結果は回転なしで比較する。

列中心化した行列を別の記号で定義

$$\mathbf{C} = [\boldsymbol{c}_g\ \boldsymbol{c}_a\ \boldsymbol{c}_t\ \boldsymbol{c}_u], \quad \hat{\mathbf{C}} = [\hat{\boldsymbol{c}}_g\ \hat{\boldsymbol{c}}_a\ \hat{\boldsymbol{c}}_t\ \hat{\boldsymbol{c}}_u]$$

$$\mathbf{J} = I_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^\top, \qquad n = |\Omega|$$

$$\mathbf{A} = \mathbf{J}\mathbf{C}, \qquad \hat{\mathbf{A}} = \mathbf{J}\hat{\mathbf{C}}$$

$\mathbf{C}, \hat{\mathbf{C}}, \mathbf{A}, \hat{\mathbf{A}} \in \mathbb{R}^{n\times 4}$。

I_n：単位行列、$\mathbf{1}_n$：全要素 1 のベクトル。$\mathbf{J}$ は定義上の表記で、巨大行列の実生成は不要。

直交 Procrustes 整合（列中心化の場合の定義）

$$\hat{\mathbf{A}}^\top \mathbf{A} = U\Sigma V^\top \quad \text{（特異値分解）}$$

$$Q^\star \in \underset{Q^\top Q = I_4}{\arg\min} \|\hat{\mathbf{A}}Q - \mathbf{A}\|_F^2, \qquad Q^\star = UV^\top$$

$U, V, Q^\star \in \mathbb{R}^{4\times 4}$、$\Sigma$：特異値を並べた対角行列。$\|\cdot\|_F$ は Frobenius ノルム。

$$\rho_k^{\mathrm{rot}} = \mathrm{corr}\big((\hat{\mathbf{A}}Q^\star)_{:,k}, \mathbf{A}_{:,k}\big)$$

$(:, k)$ は (g, a, t, u) に対応する第 k 列を表す。

- 真値を使った事後の診断。直交変換には反転も含む。
- 全列の二乗誤差を最小化する。各成分の相関の最大化や、その上限を保証しない。
- 尺度差や任意の線形混合を除去するものではない。

図の再解析で列標準化も行ったかは未照合。上式は列中心化のみの場合を明示したもの。

Appendix 学習予算による変化

中心化の改善幅は学習予算に依存

corrected MAE	60 / 8	240 / 24
経験的 ANOVA	0.05443	0.05443
中心化なし	0.05422	0.04832
中心化あり	**0.04828**	**0.04679**
あり−なし	−0.00594	−0.00153

各列は最大epoch / patience。中心化ありは5 seed全勝を維持するが、差は縮む。

240 epochでも未収束（中心化あり4/5 runが上限）。収束後の優劣は確定していない。

学習予算で動く所見（日と交互作用の分散比の順序、性能差の大きさ）は主張に使わない。担当範囲の固定は中心化の帰結で、予算に依らない。

2-Exp-40 / 48（PR #55）、5 seed。

Appendix 追加検証：成分差し替えと日マスク学習

日潜在を差し替えたときの軸間漏れ

漏れ比	全格子	観測セル
中心化あり	**6.5×10^{-7}**	**0.165**
中心化なし	0.568	0.543
潜在分割のみ	0.400	0.397

全格子での漏れほぼゼロは、中心化した出力構造の帰結。実装と比較手法との差を確認した。

欠品を除いた観測セル上では漏れが残る。 潜在次元の意味や因果的分離まで保証しない。

日マスク学習の効果は用途によって異なる

診断	2-Exp-49の結果
短履歴の時間帯推定	7日で相関0.551 経験＋最適縮小0.548
店舗間移植の強化	支持されず
隠した日の day 相関	0.012 → 0.137 事前閾値0.30未達
再構成MAEの退行	M1 +5.35% tail7 +2.39%

短履歴での改善と全窓の精度を両立する条件を検討する。未知日への一般化は未達。

左：2-Exp-50（PR #56）、5 seed　右：2-Exp-49（PR #57）、5 seed。比較条件は実験ごとに異なる。

Appendix 探索解析：潜在情報と店舗をまたいだ再利用

店舗・商品 ID と潜在表現の関連

系列間の分散	店舗で説明	残りを商品で説明
z_g	75.5%	15.6%
z_a の平均	10.3%	62.5%
z_u の平均	25.5%	56.2%

潜在ブロックごとにIDとの関連は異なる。ただし、店舗と商品の因果的な要因分離を示すものではない。

z_g に店舗情報が含まれても、出力スカラー g が店舗の需要水準を表すとは限らない。

他店舗の同じ商品から残差格子を復元

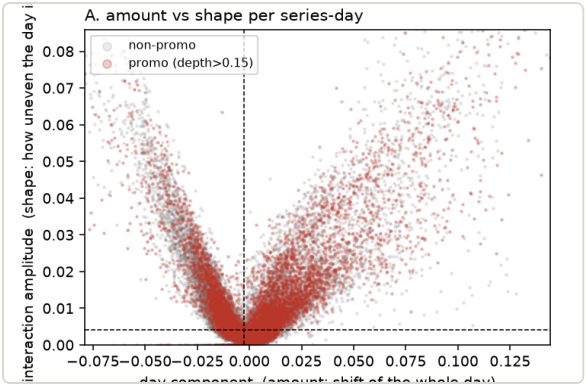
方法	残差MAE	対経験法の勝率
経験プロファイル加算	0.0628	—
潜在・中心化あり	**0.0566**	97.2%
潜在・中心化なし	0.0582	74.6%

同じ情報源を用いたleave-one-series-outの探索評価で、表現の再利用可能性を示唆。

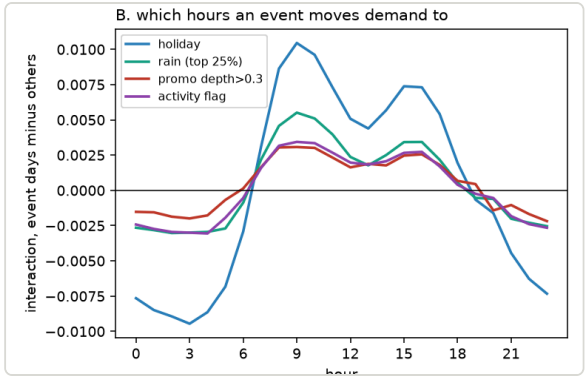
利得を中心化やDecoderの非線形性だけに帰属するには、要因を分けた比較が必要。

評価1,500系列、5 seed。IDとの関連と移植の精度は別の診断であり、一方から他方の原因を確定しない。

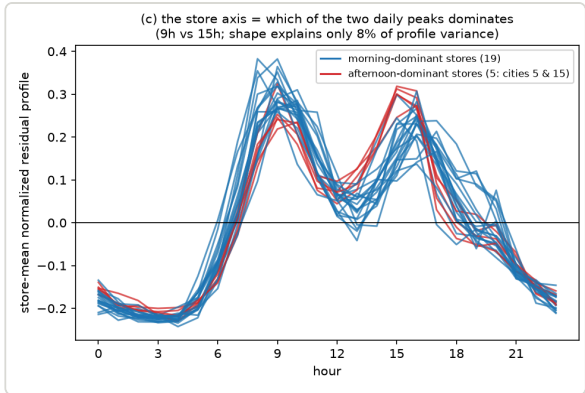
Appendix 探索図：量と形、イベントが動かす時間帯、店舗の午後ピーク



量 vs 形（系列 × 日、評価 1,500 系列）。横：日成分、縦：その日の交互作用の RMS。赤：割引の深さ > 0.15。考察 (1/3) の 2 軸をそのまま描いたもの。



イベントが動かす時間帯。イベント日と他の日の交互作用の差。休日（青）は大きく、雨・割引・販促は**同じ形を弱く呼び出す**（相互相関 0.97 以上）。



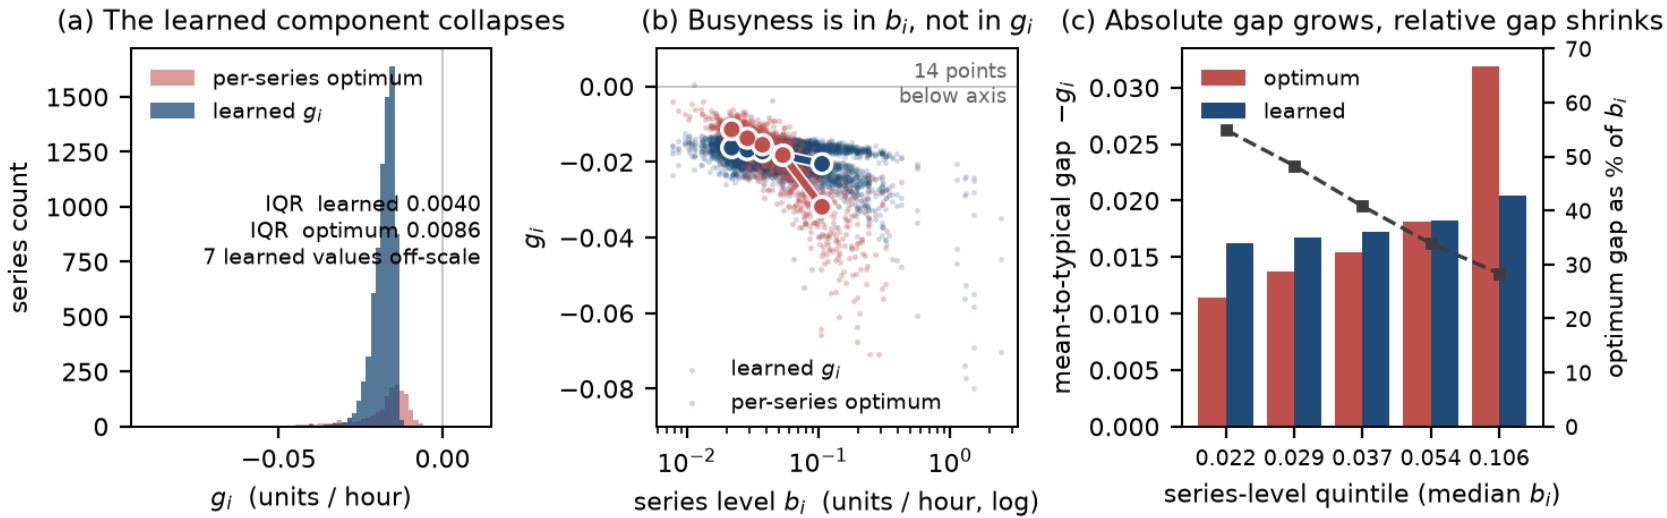
店舗の午後ピーク。店舗平均の正規化残差プロファイル。赤：午後ピーク店舗（都市 5・15 の 5 店舗）。考察 (2/3) PC3 に対応する店舗側の軸。形の分散に占める店舗差は 8%。

振幅の「商品」帰属には売上水準の効果が含まれる：商品の日内振幅は平均売上とほぼ比例（約 98% が水準効果）。水準で割った相対振幅でも商品側に帰属するが R^2 は 0.21。PC1「メリハリは商品の性質」は水準込みの言い方で、水準を除いた商品固有の性質はその一部。

左・中：2-Exp-44 seed 17（exploratory）　右・注意書き：潜在の店舗軸・商品軸分解（5 seed、評価 1,500 系列）

Appendix 全期間成分の学習値と、系列別の最適定数

平均水準を持つ b に対し、**g は全セルへ同じ値を加える補正**として働く。



青：学習済み g（5 seed をプール）　赤：他成分を固定した系列別の最適定数（seed 17）

L1 学習との関係
他成分を固定すると、最適な g は**残った残差の中央値**。平均基準からの補正には、損失関数の選択が関わる。

読み取りの限界
この図では学習値の分布が狭い。**系列の忙しさを表す指標とは解釈しにくい**。赤との開きが未知データで埋まるかは未検証。

Appendix 全期間成分の最適定数と、解釈の条件

日・時間帯・交互作用を固定したとき、g の L1 最適値は残りの中央値。

$$g_i^\star = \mathrm{median}_{(d,h)\in\Omega_i}\left(r_{i,d,h} - \hat{a}_{i,d} - \hat{t}_{i,h} - \hat{u}_{i,d,h}\right)$$

$\Omega_i = \{(d,h) : m_{i,d,h} = 1\}$：系列 i の観測セル集合（非空）。$g_i^\star$ は L1 最小化解の一つで、中央値が一意でない場合もある。

基準値と損失の組合せ

b は観測売上の系列平均。g は他成分を考慮した後の定数補正なので、単純な「売上中央値−平均」とは一般に一致しない。

基準値を中央値へ変えても、残りの中央値が0になる保証はない。gが不要になるかは再学習して検証する。

図から分かる範囲

PR #58の赤は評価対象の実測値から求めた最適値。青との開きは、未知データで達成できる改善量を示さない。

学習値の分布が狭い理由は未確定。学習量、モデル容量、共有学習による縮小などを切り分ける。

出力の担当範囲が定まることと、実世界の要因として解釈できることを区別する